

DECK 2 • COURS ML

Preparation des donnees

Obtenir une base de travail propre avant de modeliser

Cours ML • ESGI • 1 h 30

Lewis Hounkpevi

Avant de nettoyer : cadrer

1

Problematique metier

Comprendre et formaliser le besoin.

2

Bases & variables

Datamap / dictionnaire des donnees.

3

Strategie d'analyse

Definir le plan de traitement.

Les etapes du nettoyage

- Faire le point des variables : type, role, signification.
- Valeurs manquantes : les detecter et les traiter.
- Valeurs aberrantes : outliers, erreurs ou valeurs reelles ?
- Relations entre variables : correlations, redondances.



Normalisation

Mettre les variables a la meme echelle avant certains algorithmes (KNN, SVM, reseaux).

Traiter les valeurs manquantes

Supprimer

- Lignes ou colonnes concernees.
- Si peu de donnees touchees.
- Attention a ne pas trop reduire.
- Risque de biais.

Imputer

- Moyenne / mediane (numerique).
- Mode (categoriel).
- Methode raisonnee metier.
- Methodes plus sophistiquees.

Valeurs extremes / aberrantes

- Detecter si c'est une erreur de saisie ou une vraie valeur.
- Si erreur : traiter comme une valeur manquante.
- Sinon : adopter une strategie adaptee (parfois normaliser).



Exemple

Un lyceen de 50 ans : aberration probable a investiguer, pas a supprimer aveuglement.

Selection des variables et du champ

- Sur les colonnes : ecarter variables trop incompletes ou redondantes.
- Eviter les biais : par exemple un biais de selection des observations.
- Sur les lignes : supprimer les doublons, definir le champ d'etude.



Etape cle

Garder ce qui est pertinent : c'est la base de tout le reste de l'analyse.

Pandas en quelques lignes

●●● tp_dataprep_2_sale.ipynb

```
import pandas as pd
df = pd.read_csv('penguins_dirty.csv')

df.info() # types et NaN
df.describe(include='all') # stats par colonne
df.drop_duplicates(inplace=True)
df['body_mass_g'] = df['body_mass_g'].clip(lower=0)
df['sex'] = df['sex'].fillna(df['sex'].mode()[0])
```

Diagnostic, dedoublonnage, traitement des outliers et des manquants en quelques appels.

TP : Penguins propre, sale et nettoye

- TP1 : analyse descriptive sur donnees deja propres.
- TP2 : pipeline de nettoyage complet sur donnees sales.
- TP3 : analyse et visualisation sur les donnees nettoyees.
- Imputation par mediane de groupe (par espece).



Resultat attendu

Un DataFrame propre, documente,
pret pour l'entrainement d'un modele.

A RETENIR

Preparation des donnees

- Toujours cadrer la problematique metier avant de nettoyer.
- Nettoyer : manquantes, aberrantes, types, relations, normalisation.
- Imputer (moyenne/mediane/mode) ou supprimer avec parcimonie.
- Selectionner les bonnes variables = base de travail propre.
- Une fois propre, place a l'analyse et la visualisation (deck suivant).