

DECK 3 • COURS ML

Analyse et visualisation des données

Comprendre les données avant de modéliser

Cours ML • ESGI • 1 h

Lewis Hounkpevi

Statistiques descriptives

Variables numeriques

- Moyenne, min, max.
- Ecart-type.
- Mediane.
- Distribution (histogramme).

Variables categorielles

- Decompte des categories.
- Mode.
- Frequences.
- Tableaux croises.

Trouver les relations entre variables


Numerique $\leftrightarrow$ Numerique

- Table de correlation.
- Coefficient de Pearson.
- Nuages de points.
- Detecter la redondance.

Categoriel $\leftrightarrow$ Categoriel

- Test du χ^2 .
- V de Cramer.
- Tableaux de contingence.
- Mesurer l'association.

Lire une table de corrélation



Rouge = corrélation positive, bleu = négative ; valeur absolue proche de 1 = lien fort.

Quel graphique pour quelle variable ?




Histogramme

Distribution d'une variable numerique.




Boxplot

Numerique par groupe categoriel.



Scatter

Deux variables numeriques.



Barplot

Decompte d'une variable categorielle.

A quoi sert la visualisation ?

- Resumer : synthetiser l'information contenue dans les donnees.
- Relier : représenter les relations entre variables.
- Decider : orienter les choix de traitement.
- Anticiper : entrevoir les resultats du modele.



Le principe

Une bonne visualisation resume l'information, elle ne la remplace pas.

Une viz utile, pas decorative

- Choisir le bon graphique selon le type de variable.
- Mettre en evidence l'essentiel, pas le superflu.
- Une visualisation doit clarifier, jamais complexifier.



Regle d'or

Si un graphique demande une longue explication, il a sans doute echoue.

TP : analyse descriptive complete

- Reprendre le TP 02 (Supervise) ou le TP 05 (Preparation).
- Calculer moyenne, mediane, ecart-type par variable.
- Construire la table de correlation (Pearson).
- Croiser deux variables categorielles (chi2, V de Cramer).



Objectif

Produire un rapport d'analyse descriptive complet avant toute modelisation.

A RETENIR

Analyse et visualisation des donnees

- Decrire : moyenne et ecart-type pour le numerique, decomptes et mode pour le categoriel.
- Relier : correlation de Pearson pour le numerique, χ^2 et V de Cramer pour le categoriel.
- Visualiser pour resumer, relier, decider et anticiper.
- Une bonne visualisation clarifie l'information, elle ne la complexifie pas.
- Ces methodes se pratiquent dans les TP 02 et 05.