

DECK 6 • COURS ML

Les difficultes du ML

Pourquoi un projet echoue, et comment l'eviter

Cours ML • ESGI • 1 h 30

Lewis Hounkpevi

Les difficultes liees aux donnees

- Echantillon non representatif : modele non extrapolable (biais).
- Donnees de mauvaise qualite : valeurs aberrantes et manquantes.
- Variables non pertinentes : mauvaises features, mauvais modele.
- Faible quantite de donnees : impossible de generaliser.



A retenir

Un modele appris sur un echantillon biaise reste biaise, peu importe sa sophistication.

Le feature engineering


- Conserver les variables pertinentes pour le meilleur modele.
- Selection des variables : garder les plus utiles.
- Extraction et collecte de nouvelles variables.



Coeur du metier de data scientist

De bonnes variables valent souvent mieux qu'un algorithme sophistique.

Sur-apprentissage vs sous-apprentissage



Trop simple : rate la tendance. Trop complexe : apprend le bruit. L'objectif est l'équilibre.

Comprendre les deux excès

Sur-apprentissage (overfitting)

- Modèle trop complexe.
- Apprend le bruit par cœur.
- Excellent sur le train.
- Mauvais sur le test.

Sous-apprentissage (underfitting)

- Modèle trop simple.
- Rate la tendance.
- Mauvais sur le train.
- Mauvais sur le test.

Comment corriger ?

Contre l'overfitting

- Simplifier le modele.
- Plus de donnees d'apprentissage.
- Reduire le bruit.
- Regularisation.

Contre l'underfitting

- Modele plus puissant.
- De meilleures variables.
- Moins de contraintes.
- Plus de parametres.

TP : reperer les pieges

- TP 05 : diagnostiquer qualite, manquants, aberrants sur Penguins.
- TP 02 : comparer train et test pour reperer le sur-apprentissage.
- Comparer un modele simple et un modele complexe sur les memes donnees.



Reflexe

Avant d'ameliorer l'algorithmme, verifie toujours la qualite des donnees.

A RETENIR

Les difficultes du ML

- Le nerf de la guerre, ce sont les donnees, pas l'algorithme.
- Risques : echantillon biaise, mauvaise qualite, features inutiles.
- Feature engineering : selectionner et creer de bonnes variables.
- Trouver l'equilibre entre sur- et sous-apprentissage.
- Ces pieges se detectent au TP 05 et se corrigent au TP 02.