

DECK 7BIS • COURS ML

Explicabilite et choix du modele final

Shapley values, criteres de selection, stockage et inference simple

Cours ML • ESGI • 1 h 30

Lewis Hounkpevi

Pourquoi expliquer un modele ?

- Un modele precis mais opaque est difficile a faire valider par le metier.
- Certains secteurs l'exigent : credit, sante, assurance (reglementation, audit).
- Expliquer permet de detecter un biais ou une variable suspecte (data leakage).



Boite noire

Random Forest, XGBoost, reseaux de neurones sont performants mais peu lisibles par default.

Modeles interpretables vs modeles boite noire

Interpretables

- Regression lineaire : coefficients directs.
- Arbre de decision peu profond : regles lisibles.
- Faciles a expliquer, parfois moins precis.

Boite noire

- Random Forest, Gradient Boosting (XGBoost).
- Reseaux de neurones.
- Tres precis, mais logique interne opaque.

SHAP : le principe des valeurs de Shapley

- Concept issu de la theorie des jeux : repartir equitablement une contribution entre joueurs.
- Chaque variable est un joueur, la prediction est le gain a repartir.
- La valeur de Shapley d'une variable mesure son impact sur l'ecart a la moyenne.



Propriete cle

prediction = valeur de base + somme des valeurs de Shapley de chaque variable.

Calculer les valeurs de Shapley

```
explicabilite.py
```

```
import shap

explainer = shap.TreeExplainer(model)
shap_values = explainer.shap_values(X_test)

shap.summary_plot(shap_values, X_test)
shap.force_plot(explainer.expected_value,
                 shap_values[0], X_test.iloc[0])
```

TreeExplainer est optimisé pour les modèles à base d'arbres (Random Forest, XGBoost, LightGBM).

Lire les graphiques SHAP

- Summary plot : importance globale, une ligne par variable, triée par impact moyen.
- Force plot : explique UNE prediction, variable par variable.
- Une variable a forte valeur SHAP n'est pas forcément causale, juste influente pour le modele.



Local vs global

Le summary plot explique le modele en general, le force plot explique un individu precis.

Trois criteres pour choisir le modele final

1

Minimiser les erreurs

RMSE, MAE, taux d'erreur : le plus bas possible sur le jeu de test.

2

Maximiser la performance

R2, F1, AUC : la capacite a bien generaliser, pas juste bien apprendre.

3

Maximiser l'explicabilite

Pouvoir justifier une prediction aupres du metier ou d'un regulateur.

Arbitrer performance et explicabilite

- Le modele le plus precis n'est pas toujours le bon choix final.
- Un petit gain de performance ne justifie pas toujours une perte totale d'explicabilite.
- SHAP permet de garder un modele boite noire tout en recuperant de l'explicabilite a posteriori.



Regle pratique

A performance egale, preferer le modele le plus simple a expliquer.

Stocker le meilleur modele

```
● ● ● sauvegarde_modele.py
```

```
import joblib

# apres avoir compare plusieurs modeles et choisi le meilleur
joblib.dump(best_model, 'modeles/best_model.pkl')
joblib.dump(scaler, 'modeles/scaler.pkl')

print('Modele sauvegarde : best_model.pkl')
```

joblib est recommande pour les objets scikit-learn (plus efficace que pickle sur les gros tableaux numpy).

Inference simple, sans API

 inference.py

```
import joblib
import pandas as pd

model = joblib.load('modeles/best_model.pkl')
scaler = joblib.load('modeles/scaler.pkl')
donnees = pd.read_csv('donnees_a_predire.csv')
donnees['prediction'] = model.predict(scaler.transform(donnees))
donnees.to_csv('predictions.csv', index=False)
```

Aucun serveur ni API nécessaire : un script Python suffit pour prédire et sauvegarder le résultat.

TP : du modele final aux predictions

- 1 Entrainer 2 ou 3 modeles candidats (ex : regression, arbre, Random Forest).
- 2 Comparer leurs metriques d'erreur et de performance sur le jeu de test.
- 3 Calculer les valeurs de Shapley du meilleur candidat et lire le summary plot.
- 4 Choisir le modele final en arbitrant erreur, performance et explicabilite.
- 5 Sauvegarder le modele (joblib), puis charger et predire sur de nouvelles donnees dans un CSV.

Objectif

Boucler le cycle complet : entrainer, expliquer, choisir, stocker, predire.

Explicabilite et choix du modele final

- Un modele boite noire performant sans explication est difficile a valider et a deployer.
- SHAP attribue a chaque variable sa contribution a une prediction (valeurs de Shapley).
- Le modele final s'evalue sur trois axes : erreur minimale, performance robuste, explicabilite suffisante.
- Stocker le modele (joblib) permet de le reutiliser sans refaire l'entrainement.
- Une inference simple charge le modele, predit sur de nouvelles donnees et sauvegarde le resultat en CSV.