

DECK 8 • COURS ML


Mettre le ML supervise en pratique

Du dataset brut au modele deploye : le pipeline complet

Cours ML • ESGI • 1 h 30

Lewis Hounkpevi

La methode en un coup d'oeil



Le meme pipeline, du dataset brut au modele deploye, quel que soit l'algorithmhe choisi.

Le pipeline supervise en quatre phases

1

Donnees & exploration

Preparer, analyser et visualiser avant de modeliser.

2

Modelisation

Separer train/test (80/20), entrainer un modele adapte a la tache.

3

Evaluation & choix

Mesurer erreur, performance et explicabilite ; choisir le modele final.

4

Mise en production

Stocker, deployer, inferer et faire vivre le modele.

Etape 1 : preparer les donnees

- Nettoyer : valeurs manquantes, doublons, types incohérents.
- Encoder les variables catégorielles (one-hot, ordinal...).
- Cadrer X (les variables) et y (la cible à prédire).



Garbage in, garbage out

Un modèle ne peut pas compenser des données mal préparées.

Etape 2 : analyser et visualiser

- Distributions, correlations, valeurs aberrantes.
- Comprendre les relations entre variables avant de choisir un algorithme.
- Detecter un eventuel desequilibre de classes.



Objectif

Anticiper ce que le modele pourra, ou ne pourra pas, apprendre.

Etape 3 : separer train et test (80/20)

- 80% pour entrainer, 20% pour evaluer sur des donnees jamais vues.
- Stratifier le split en classification (meme proportion de classes).
- Validation croisee pour regler les hyperparametres.



Regle d'or

Ne jamais evaluer un modele sur les donnees qui ont servi a l'entrainer.

Etape 4 : entrainer le modele

- Choisir un algorithme adapte a la tache (regression, classification).
- Regler les hyperparametres cles (k, profondeur, taux d'apprentissage...).
- Comparer plusieurs algorithmes (lineaire, arbre, foret, boosting...).



Meme reflexe partout

Le protocole d'entrainement se ressemble d'un algorithme a l'autre.

Etape 5 : evaluer les resultats

- Classification : matrice de confusion, precision, rappel, ROC-AUC.
- Regression : R^2 , RMSE, MAE, analyse des residus.
- Toujours evaluer sur le jeu de test, jamais sur le train.



Reflexe qualite

Un bon score ne suffit pas : le resultat doit avoir du sens pour le metier.

Etape 6 : choisir le modele final

- Minimiser l'erreur, maximiser la performance : deux reflexes naturels.
- Mais aussi maximiser l'explicabilite : un modele boite noire se justifie avec SHAP.
- Le modele le plus precis n'est pas toujours le bon choix final.



Arbitrage

Erreur, performance et explicabilite :
trois criteres, pas un seul.

Etape 7 : deployer et faire vivre le modele

- Stocker le modele final (joblib, torch.save...) pour le reutiliser sans reentrainer.
- Inference simple : charger le modele, predire sur de nouvelles donnees, sauvegarder le resultat.
- Cycle de vie : surveiller la derive des donnees, reentrainer periodiquement.



La vraie valeur

Un modele precis mais jamais deploye n'a aucune valeur.

TP : appliquer la methode (supervise)

- 1 Cadrer le cas : definir X, y et l'objectif metier.
- 2 Preparer, analyser et visualiser les donnees.
- 3 Separer train et test (80/20), entrainer plusieurs modeles.
- 4 Evaluer avec la metrique adaptee et choisir le modele final.
- 5 Stocker le modele et faire une inference simple sur de nouvelles donnees.

Objectif

Suivre le pipeline complet, du dataset brut au modele deploye.

A RETENIR

Mettre le ML supervise en pratique

- Le pipeline supervise suit toujours les memes etapes : preparer, explorer, entrainer, evaluer, choisir, deployer.
- Le split train/test (80/20) est indispensable pour mesurer la vraie performance.
- Le choix du modele final arbitre erreur, performance ET explicabilite.
- Deployer, ce n'est pas juste predire : c'est stocker, inferer et surveiller dans le temps.
- Illustrations : classification (spam, credit) et regression (prix immobilier).