

DECK 8BIS • COURS ML

Mettre le ML non supervise en pratique

Du dataset brut aux segments qualifiés : le pipeline complet

Cours ML • ESGI • 1 h 30

Lewis Hounkpevi

Le pipeline non supervise en quatre phases

1

Donnees & exploration

Preparer, analyser et visualiser avant de regrouper.

2

Modelisation

Entrainement d'un algorithme de clustering sur tout le jeu de donnees.

3

Evaluation & visualisation

Mesurer la qualite des clusters et les visualiser.

4

Qualification & decision

Nommer les clusters, les integrer, decider.

Etape 1 : preparer les donnees

- Nettoyer : valeurs manquantes, doublons, types incohérents.
- Normaliser les variables (indispensable : le clustering est sensible à l'échelle).
- Pas de cible y à définir : seulement les variables X .



Difference cle

Sans étiquette, la normalisation compte encore plus qu'en supervisée.

Etape 2 : analyser et visualiser

- Distributions, correlations entre variables.
- Reduction de dimension (PCA) pour un premier aperçu visuel.
- Reperer d'éventuels groupes naturels à l'œil nu.



Objectif

Se faire une première idée du nombre et de la forme des groupes.

Etape 3 : entrainer le modele

- Choisir un algorithme adapte (K-means, DBSCAN, CAH...).
- Pas de split train/test : le clustering utilise tout le jeu de donnees.
- Choisir le nombre de clusters k avec la methode du coude ou la silhouette.



Pas de bonne reponse unique

Plusieurs algorithmes peuvent donner des segmentations differentes, toutes valides.

Etape 4 : evaluer les clusters

- Silhouette : proche de 1 = points bien classes dans leur cluster.
- Inertie intra-classe (a minimiser) et inter-classe (a maximiser).
- Sans etiquette, l'interpretation metier compte autant que le score.




Astuce

Si un label cache existe, ARI et NMI comparent le clustering a la verite.

Visualiser les clusters

Clusters K-means (k=3)



Une projection 2D (PCA) permet de vérifier visuellement que les clusters ont du sens.

Etape 5 : integrer les resultats

- Rattacher un identifiant de cluster a chaque observation.
- Injecter ce cluster_id dans le SI, le CRM ou l'entrepot de donnees.
- Rendre le resultat exploitable par d'autres equipes.



Reflexe

Un cluster qui reste dans un notebook n'a aucun impact metier.

Etape 6 : qualifier les clusters

- Analyser le profil de chaque groupe (moyennes, variables discriminantes).
- Donner un nom métier a chaque cluster (ex : gros acheteurs occasionnels).
- Verifier que chaque groupe est bien distinct et actionnable.



De chiffre a sens

Un cluster numero 2 ne dit rien ; un segment nomme, si.

Etape 7 : prise de decision

- Traduire chaque segment en action concrete (offre, message, priorite).
- Partager les segments qualifiees avec les parties prenantes.
- Mesurer l'impact des actions et ajuster la segmentation si besoin.



La vraie valeur

Un clustering precis mais jamais utilise n'a aucune valeur.

TP : appliquer la methode (non supervise)

- 1 Cadrer le cas : definir X et l'objectif metier (pas de y).
- 2 Preparer, normaliser, analyser et visualiser les donnees.
- 3 Entrainer un ou plusieurs algorithmes de clustering sur tout le jeu.
- 4 Evaluer (silhouette, inertie) et visualiser les clusters obtenus.
- 5 Qualifier chaque cluster et proposer une decision actionnable.

Objectif

Suivre le pipeline complet, du dataset brut aux segments qualifies.

A RETENIR

Mettre le ML non supervise en pratique

- Le clustering n'a pas de y : pas de split train/test, tout le dataset sert à l'entraînement.
- Le nombre de clusters (k) se choisit avec le coude ou la silhouette, pas au hasard.
- Visualiser les clusters (PCA, scatter) est indispensable pour vérifier qu'ils ont du sens.
- Qualifier chaque cluster avec des mots métier transforme un chiffre en décision.
- Illustration : segmentation de clients (TP 01, K-means).