

DECK 9 • COURS ML • TP 03

Apprentissage par renforcement

Agent, environnement, recompense, politique

Cours ML • ESGI • 2 h

Lewis Hounkpevi

Le contexte du RL

- Pas de dataset : l'agent genere sa propre experience.
- Cas d'usage : jeux (AlphaGo), robotique, finance, pub.
- Hypothese : un signal de recompense est disponible.
- Difficulte : recompenses parfois rares ou differees.



Difference cle

En supervise on a la bonne reponse.
En RL on a un signal, et il faut le chercher.

Les quatre concepts clés

A

Agent

Celui qui decide.

E

Environnement

Le monde simule ou reel.

S

Etat (state)

Ce que l'agent observe.

R

Recompense

Le signal a maximiser.

Le cycle d'interaction

1

Observer

L'agent perçoit l'état courant.

2

Agir

Il choisit une action selon sa politique.

3

Apprendre

Il met à jour sa politique avec la récompense.

Exploration vs exploitation

- Exploiter : prendre l'action que l'on croit la meilleure.
- Explorer : tester une action moins connue.
- Strategie epsilon-greedy : exploiter avec proba $1 - \epsilon$.
- Reduire epsilon au fil de l'entrainement.



Le dilemme

Trop d'exploitation : on rate des chemins meilleurs. Trop d'exploration : on n'apprend rien.

Q-Learning tabulaire en quelques lignes

```
tp_reinforcement.ipynb

for episode in range(N_EPISODES):
    s = env.reset()
    while not done:
        a = epsilon_greedy(Q[s], eps)
        s_next, r, done, _ = env.step(a)
        target = r + gamma * Q[s_next].max()
        Q[s, a] += alpha * (target - Q[s, a])
        s = s_next
```

La mise à jour Q-learning suit l'équation de Bellman, en remontant la récompense d'un pas.

Q-Learning vs DQN

Q-Learning tabulaire

- Table d'etats x actions.
- Marche si l'espace est petit.
- Convergence garantie sous conditions.
- Inutilisable sur image, pixels, etc.

DQN

- Q remplace par un reseau neuronal.
- Marche sur de gros espaces (Atari).
- Replay buffer et target network.
- Pas de garantie theorique forte.

PPO : acteur-critique

- Deux reseaux : acteur (politique) et critique (valeur).
- L'acteur propose une action, le critique estime sa valeur.
- PPO contraint la mise a jour pour rester proche de l'ancienne politique.
- Algo de reference moderne, stable et performant.



Stable-Baselines3

PPO, DQN, A2C, SAC : tous dispo en une ligne d'import dans le TP 03.

TP : CartPole et MountainCar

- Q-Learning tabulaire from scratch.
- DQN et PPO via Stable-Baselines3.
- Comparer les courbes d'apprentissage.
- Visualiser les politiques apprises.



Objectif

Comprendre que le meme probleme peut se resoudre par 3 algos avec 3 trade-offs differents.

A RETENIR

Apprentissage par renforcement

- Un agent RL apprend par interaction, sans dataset figé.
- Q-Learning maintient une table d'états x actions.
- DQN remplace la table par un réseau de neurones.
- PPO entraîne acteur et critique conjointement.
- Le compromis exploration / exploitation est central.