

DECK 11 (BONUS) • COURS ML • TP 06

LLM et prompt engineering

Comprendre les LLM et interagir efficacement avec eux

Cours ML • ESGI • Seance bonus • 1 h 30

Lewis Hounkpevi

Qu'est-ce qu'un LLM ?

- LLM : Large Language Model, un grand modele de langage.
- Entraîne sur d'immenses corpus de texte issus du web.
- Il prédit le mot (token) suivant le plus probable.



Predire le prochain token

Un LLM ne 'comprend' pas : il calcule la suite la plus probable a votre texte.

Comment fonctionne un LLM

1

Tokeniser

Le texte est decoupe en tokens
(morceaux de mots).

2

Predire

Le modele estime le token suivant le
plus probable.

3

Generer

On repete token apres token pour
construire la reponse.

Un LLM combine les 3 types d'apprentissage

1

Auto-supervise

Predire le mot suivant sur des milliards de textes : il apprend la langue.

2

Supervise

Des humains ecrivent des reponses modeles : il apprend a obeir aux consignes.

3

Renforcement

Des humains notent les reponses (RLHF) : il apprend a bien se comporter.

Trois techniques de base

1

Zero-shot

On pose la question directement, sans exemple.

2

Few-shot

On donne quelques exemples pour guider le format.

3

Chain-of-thought

On demande un raisonnement étape par étape.

Anatomie d'un bon prompt

1

Role & contexte

Donner un role et le cadre de la tache.

2

Instruction claire

Dire precisement ce que l'on attend.

3

Format de sortie

Exiger la forme : liste, tableau, longueur.

Un prompt vague vs un prompt précis

Prompt vague

- Parle-moi du marketing.
- Aucun role donne.
- Pas de format attendu.
- Reponse generique et floue.

Prompt précis

- Role : expert marketing.
- Tache et contexte definis.
- Format : 5 puces courtes.
- Reponse ciblee et exploitable.

Sortie structuree (JSON)

- Decrire le schema attendu dans le prompt.
- Donner un exemple de sortie JSON.
- Demander 'reponds uniquement par du JSON valide'.
- Parser avec `json.loads` et gerer les erreurs.



Indispensable

Si la sortie est consommee par du code, le JSON structure est la seule option fiable.

API vs modele local

Anthropic API

- Claude Haiku, Sonnet, Opus.
- Rapide, performant.
- Necessite une cle API.
- Cout au token.

Modele local (HF)

- Qwen, Llama, Mistral, etc.
- Gratuit, hors ligne.
- Plus lent sur CPU.
- Qualite moindre sur petit modele.

Le helper dual-mode du TP

```
●●● tp_prompt_engineering.ipynb
```

```
load_dotenv()
USE_ANTHROPIC = bool(os.getenv('ANTHROPIC_API_KEY'))

def complete(prompt, system=None, max_tokens=512):
    if USE_ANTHROPIC:
        return _call_claude(prompt, system, max_tokens)
    return _call_local_qwen(prompt, system, max_tokens)
```

Bascule automatique entre API Claude et modele local selon la presence de la cle.

Les limites des LLM

- Hallucinations : il invente des faits avec assurance.
- Biais : il reproduit les biais présents dans les données.
- Date de coupure : ses connaissances s'arrêtent à une date.
- Confidentialité : attention aux données sensibles envoyées.



Pas de vrai calcul

Logique et arithmétique restent fragiles : vérifier les résultats chiffrés.

Toujours garder l'esprit critique

- Un LLM est un assistant, pas une source de verite.
- Verifier les faits importants et les chiffres cites.
- Reformuler ou fournir des sources pour reduire les erreurs.



Human in the loop

La decision finale et la verification restent la responsabilite de l'humain.

Les principaux LLM grand public

1

ChatGPT

OpenAI. Le plus connu, ecosystème GPT très complet.

2

Gemini

Google. Intègre à la recherche et aux outils Google.

3

Claude

Anthropic. Axe sécurité, longs contextes, rédaction.

Comment choisir un LLM ?

- La tâche : code, redaction, analyse, synthese vocale.
- Le contexte : taille des documents a traiter d'un coup.
- Les contraintes : cout, confidentialite, open source (Mistral, Llama).



L'integration

API, outils, ecosysteme existant : le choix depend aussi de ce qui entoure le modele.

TP : techniques de prompting

- Zero-shot : classifier un sentiment.
- Few-shot : extraire des dates au format ISO.
- CoT : resoudre un probleme de mots.
- JSON : extraire des entites depuis une biographie.



A la fin

Tu sais ecrire un prompt qui produit une sortie utilisable, fiable et reproductible.

A RETENIR

LLM et prompt engineering

- Un LLM prédit le token suivant : il généralise, il ne comprend pas.
- Un bon prompt : rôle, instruction claire, format de sortie.
- Techniques clés : zero-shot, few-shot, chain-of-thought, JSON structure.
- Limites : hallucinations, biais, date de coupure : rester critique.
- Claude, ChatGPT, Gemini : le choix dépend de la tâche et du contexte.